Devoir Écrit - ADDE92-DE - Reinforcement Learning

EFREI Paris - 2024/2025

5 Mars 2025 | Durée: 1h50 | Victor Morand

INSTRUCTIONS

Comme annoncé, je pose des questions qui se veulent simples et générales sur les termes et algorithmes à bien connaître signalés dans le cours. Répondez-y clairement et efficacement sur votre copie *en numérotant bien vos réponses.*

---

1 Généralités

1.1 Quelques définitions

1. Schématisez le cadre général de l'apprentissage par renforcement (RL). Nommez et définissez les principales variables nécessaires à ce cadre. (3 pts)
2. Qu'est ce qu'un MDP et comment le définit-on ? (1 pt)
3. On se place dans le cadre d'un MDP, donner la définition des variables suivantes:
   (a) Value function V: (1 pt)
   (b) Action-Value function Q: (1 pt)
   (c) Gain G: (1 pt)
4. Qu'est ce que le "**Discount Factor**" et à quoi sert-il ? (1 pt)
5. Comment définir une fonction de récompense efficace dans un problème de RL ? Donnez un exemple concret. (1 pt)

1.2 Concepts Généraux

6. Quelle est la différence entre un algo "**Model-Free**" vs "**Model-Based**" (1 pt)
7. Quelle est la différence entre un algo "**Policy-based**" vs "**Value-based**" (1 pt)
8. Quelle est la différence entre un algo "**Off-Policy**" vs "**On-Policy**" (1 pt)
9. Comparer les méthodes basées sur la "**Temporal Difference**" (TD) vs "**Monte-Carlo**" (MC) (1 pt)

10. Décrivez succinctement ce qu'est un algorithme "**Actor-Critic**" (1 pt)

11. Expliquez le dilemme **Exploration/Exploitation** en apprentissage par renforcement. Proposez une stratégie pour gérer ce dilemme et discutez de ses avantages et inconvénients. (1 pt)

12. Expliquer la notion de **bootstrapping** dans le cas d'un algo de RL. (1 pt)

13. Qu'est-ce qu'un "**Replay buffer**" et pourquoi en utiliser ? (1 pt)

2 Algorithmes de RL

2.1 Programmation Dynamique

Nous nous plaçons dans le cadre d'un MDP (discret) *comme un labyrinthe par exemple...*

14. Au-delà de son utilisation en RL, quel est le principe de la programmation dynamique ? (1 pt)

15. Donner l'équation de Bellman appliquée à V, et expliquez pourquoi elle est utile pour résoudre le problème. (1 pt)

16. Pour le MDP ci-dessous, calculer la valeur de V manquante ($\gamma = 1$). (1 pt)

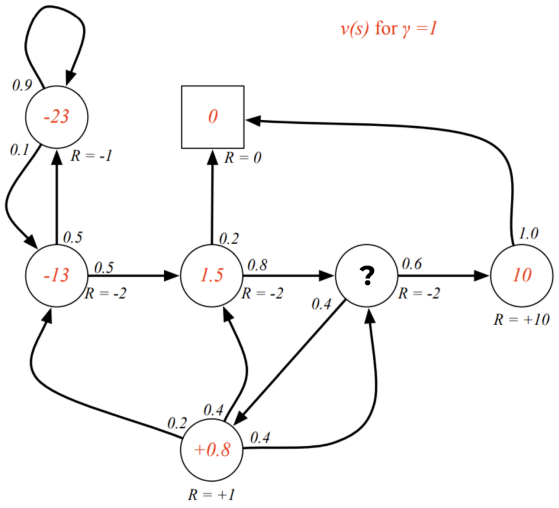

17. Décrivez un algorithme du cours utilisant la programmation dynamique. Donnez-en un pseudo-code. (3 pts)

18. Quels sont les avantages et les inconvénients de la programmation dynamique dans notre cas ? (1 pt)

19. **(Bonus)** Prouvez la validité de l'équation de Bellman, expliquez rigoureusement comment vos termes sont définis et quels théorèmes vous utilisez. (3 pts)

2.2 Méthodes Model-free

20. Citez deux politiques déterministes d'exploration possibles pour un agent de RL dans un environnement discret.

21. Voici le pseudo-code d'un algorithme bien connu:

```
Algorithm parameters: step size α ∈ (0, 1], small ε > 0
Initialize Q(s, a), for all s ∈ S⁺, a ∈ A(s), arbitrarily except that Q(terminal, ·) = 0
Loop for each episode:
    Initialize S
    Loop for each step of episode:
        Choose A from S using policy derived from Q (e.g., ε-greedy)
        Take action A, observe R, S'
        Q(S, A) ← Q(S, A) + α[R + γ max_a Q(S', a) − Q(S, A)]
        S ← S'
    until S is terminal
```

(a) Quel est le nom de cet algorithme ? (1 pt)

(b) Est-il value/policy-based ? Justifiez. (1 pt)

(c) Est-il basé sur une méthode dite "**TD**" ou bien "**Monte Carlo**" ? (1 pt)

2.3 Cas Continu

Nous nous plaçons dans cette section dans le cas où nos états et/ou nos actions dans l'environnement sont *continus*.

22. Donnez un exemple concret d'application de l'apprentissage par renforcement dans un cas continu. (1 pt)

23. Quels sont les principaux défis du cas continu en RL ? (1 pt)

24. Quel outil a-t-on à notre disposition pour appliquer les méthodes développées pour des environnements discrets à notre nouvel environnement ? (1 pt)

25. Citez un algorithme de RL utilisable dans le cas d'un environnement *d'actions et d'états continus* et décriviez brièvement son fonctionnement. (1 pt)

2.4 Deep Reinforcement Learning

26. Quel est l'intérêt principal d'utiliser des réseaux de neurones en RL ? (1 pt)

27. Dans le cas d'un robot paramétré pour implémenter π_θ, $\theta \in \mathbb{R}^d$, dans un cadre classique de RL, quelle est la fonction que l'on va chercher à optimiser ? Donnez-en le nom et la définition. (1 pt)

28. Dans le cas de **DQN**, quelle architecture utilise-t-on ? Quelles sont les entrées et sorties du réseau ? (1 pt)

29. Voici le pseudo-code d'un algorithme de RL, π est modélisé par un réseau de neurones:

> Input: a differentiable policy parameterization $\pi(a|s, \boldsymbol{\theta})$
> Algorithm parameter: step size $\alpha > 0$
> Initialize policy parameter $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ (e.g., to $\mathbf{0}$)
>
> Loop forever (for each episode):
> Generate an episode $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$, following $\pi(\cdot|\cdot, \boldsymbol{\theta})$
> Loop for each step of the episode $t = 0, 1, \ldots, T-1$:
> $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ (G_t)
> $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \gamma^t G \nabla \ln \pi(A_t|S_t, \boldsymbol{\theta})$

    (a) Quel théorème utilise-t-on ici pour optimiser π ? (1 pt)
    (b) Quel est l'avantage d'utiliser γ ici ? (1 pt)
    (c) Donner un cas concret dans lequel cet algorithme peut être limité, comment l'améliorer ? (1 pt)
    (d) **(Bonus)** Quel est le nom de cet algorithme ? (1 pt)

30. Donnez trois caractéristiques de l'algorithme **PPO**. (1 pt)

2.5 Model-based RL

31. Quelle est la principale motivation pour développer des algorithmes dits "**Model-Based**" ? (1 pt)

32. Quelle est la principale difficulté pour leur mise en oeuvre ? (1 pt)

33. **(Bonus)** Donnez un exemple d'algorithme "**Model-based**" et son utilisation à un problème concret. (1 pt)

(Total des points : 40)

Fin du sujet, ***veillez à bien le rendre avec votre copie.***
J'espère que le cours vous a plu, bonne continuation !